



Retrieval Augmented Generation (RAG)

systemy AI do wyszukiwania informacji

Bartosz Mikulski

mikulskibartosz.name

aihallucinationfix.substack.com



Zaufaj naszemu doświadczeniu

18 lat

na rynku usług IT

29 560+

przeszkolonych
osób

500+

klientów biznesowych

4 877+

zorganizowanych
szkoleń i warsztatów

GWARANCJA JAKOŚCI USŁUG



98%

zadowolonych
klientów*

* Średnia z ankiet poszkoleniowych
przeprowadzanych wśród uczestników
naszych szkoleń.



Edukacja na najwyższym poziomie

Wiedza specjalistyczna dla branży IT

Oferujemy szeroki katalog szkoleń z technologii mainstreamowych i specjalistycznych, wschodzących i legacy. Zajęcia prowadzimy w trybie warsztatowym, a programy są oparte o praktyczne know-how. Specjalizujemy się w prowadzeniu dedykowanych szkoleń technologicznych, których agendę dostosowujemy do potrzeb naszych klientów i oczekiwania uczestników.

Wybitni eksperci

Od początku naszego istnienia przeszkołiliśmy dziesiątki tysięcy osób, co pomogło absolwentom podnieść konkurencyjność na rynku pracy i jakość projektów realizowanych na co dzień. Nasze szkolenia prowadzą najlepsi trenerzy, a nasze produkty są oparte na najnowocześniejszej technologii. Ich niezawodność i dopasowanie do potrzeb klientów są możliwe dzięki zespołowi składającemu się z wybitnych ekspertów i ekspertek, którzy/e są na pierwszej linii teorii i praktyki tworzenia i wdrażania innowacji technologicznych.

NASZE POZOSTAŁE MARKI EDUKACYJNE

STACJA.IT

kodo/amacz
by sages

sages

Najlepsze standardy usług edukacyjnych

Stosujemy Standard Usługi Szkoleniowej Polskiej Izby Firm Szkoleniowych, a nasze usługi realizowane są na najwyższym poziomie, o czym świadczą stale powracający klienci oraz wdrożony certyfikat ISO 9001. Metodologia prowadzonych przez nas zajęć oparta jest na współczesnych narzędziach i dostosowana do potrzeb i oczekiwania klientów.

Ponadto jesteśmy firmą wpisaną do rejestru instytucji szkoleniowych w Wojewódzkim Urzędzie Pracy w Warszawie pod nr 2.14/00133/2019.

Zaufali nam najlepsi

Wśród naszych klientów są takie firmy jak Alior Bank, OLX Group, Bank Zachodni WBK, Orange Polska, Lufthansa i wiele innych.

STUDIA PODYPLOMOWE

Wspieramy organizację zaawansowanych kierunków studiów podyplomowych. Realizujemy zajęcia na kierunkach: Data Science, Big Data i Wizualna analityka danych, AI & Data Driven Business oraz User Experience Design – projektowanie doświadczeń cyfrowych.



Instytut Informatyki
Wydział Elektroniki i Technik Informacyjnych
Politechniki Warszawskiej



AKADEMIA
LEONA KOŽMIŃSKIEGO

Sylwetka trenera



Bartosz Mikulski

Informacje o trenerze:

<https://mikulskibartosz.name/about>

Szkolenie zdalne - zasady ogólne

1. Znaleźć spokojne i wygodne miejsce, aby móc realizować ćwiczenia i warsztaty.
2. Używamy naszych imion podczas trwania szkolenia, zamiast abstrakcyjnych loginów
3. Proszę o wyciszenie mikrofonów, kamera nie musi być włączona - w zależności od jakości połączenia nawet wyłączona.

Praca w grupie i dyskusje

1. Można podnieść rękę lub włączyć mikrofon i poczekać, aż zauważę :)
2. Pauzy to czas na reakcję lub wykonanie ćwiczenia - w tym czasie jestem dostępny do pomocy.
3. Jesteśmy otwarci na ciekawostki, komentarze są mile widziane.

Jeśli pojawią się problemy :(

1. Słaba jakość transmisji, przerwania lub inne kłopoty - proszę od razu alarmować.
2. Zniknięcie prowadzącego nie oznacza końca szkolenia ;) Dajemy sobie minutę na powrót do szkolenia, w przeciwnym przypadku umawiamy się na kilkuminutową przerwę.

Uwaga

Wszelkie materiały (treści tekstowe, wideo, ilustracje, zdjęcia itp.) wchodzące w skład szkoleń, kursów i webinarów organizowanych przez Sages są objęte prawem autorskim i podlegają ochronie na mocy Ustawy o prawie autorskim i prawach pokrewnych z dnia 4 lutego 1994 r. (tekst ujednolicony: Dz.U. 2006 nr 90 poz. 631). Kopiowanie, przetwarzanie, rozpowszechnianie tych materiałów w całości lub w części jest zabronione.

Szkolenie zdalne - przerwy

1. Każdego dnia przerwa obiadowa w okolicy godz. 13 trwająca ~45 minut.
2. Kilkuminutowe przerwy pomiędzy większymi sekcjami szkolenia.

Moduł 1: Bazowy RAG

Co to jest RAG?

Jak działają bazy wektorowe?

Wprowadzenie do Llama-index

Źródła:


mikulskibartosz.name/advanced-rag-techniques-explained

<https://mikulskibartosz.name/approximate-nearest-neighbor-vs-rag>


Co to jest RAG?

- RAG łączy wyszukiwanie (retrieval) i generowanie (generation) odpowiedzi przez model językowy.
- Najpierw mechanizm retrievera wybiera najbardziej pasujące fragmenty z bazy wiedzy.
- Wybrane treści są przekazywane do modelu, który buduje końcową odpowiedź.

Querying the Database and Synthesizing the Answer




Storing and Indexing Documents



Jak działają bazy wektorowe?

- Dane (np. tekst, obraz) zamieniane są na wektory liczb przez model ML.
- Wektory o podobnym znaczeniu znajdują się blisko siebie w przestrzeni wektorowej.
- Zapytanie użytkownika także przekształcane jest w wektor.
- Baza porównuje wektor zapytania z wektorami dokumentów za pomocą metryk podobieństwa.
- Wynikiem są najbardziej semantycznie zbliżone elementy, a nie tylko te z identycznymi słowami.

Vector search returns similar items **based on their semantic meaning**, rather than exact term matches.





<https://weaviate.io/blog/vector-search-explained>

Metryki odległości

- **Cosine Similarity** – porównuje kąt między wektorami.
- **Hamming Distance** – liczy różnice w poszczególnych pozycjach wektorów binarnych.
- **Manhattan Distance** – sumuje różnice wartości po każdej osi.

Approximate Nearest Neighbor Search



<https://weaviate.io/blog/vector-search-explained>



LlamaIndex (llamaindex.ai)

[PRODUCTS](#)[SOLUTIONS](#)[COMMUNITY](#)[PRICING](#)[BLOG](#)[CUSTOMER STORIES](#)[CAREERS](#)[BOOK A DEMO](#)[SIGN IN](#)

Redefine document workflows with AI Agents

Build agentic workflows to extract information, synthesize insights,
and take actions over the most complex enterprise documents.

[GET STARTED](#)[CONTACT SALES](#)



LlamaIndex

Dokumentacja: docs.llamaindex.ai/en/stable/api_reference

LlamaCloud

cloud.llamaindex.ai

Moduł 2: Przygotowanie danych

Wczytywanie dokumentów

Dzielenie tekstów

LlamaCloud

Transformacja danych

Obsługiwane bazy danych

Typy indeksów

Indeksowanie danych

SummaryIndex - lista dokumentów (używamy gdy dokumentów jest niewiele lub chcemy zawsze wczytać wszystko)

VectorStoreIndex - wektorowe bazy danych (wyszukiwanie przez podobieństwo znaczenia tekstu)

KeywordTableIndex - wyszukiwanie przy użyciu słów kluczowych (wyszukiwanie dokumentów z określoną wartością np. numer produktu)

PropertyGraphIndex - graf zależności między zawartością dokumentów (wyszukiwanie powiązań, np. strony umowy)

Moduł 3: Analiza błędów w RAG

Przygotowanie danych testowych

Metryki oceniające wyszukiwanie informacji oraz generowanie odpowiedzi

Sposoby pozyskiwania informacji o błędach (LLM-as-a-judge vs człowiek)

Klasyfikowanie błędów (topic modeling, clustering)

Źródła:

hamel.dev

hamel.dev/blog/posts/evals-faq

hamel.dev/blog/posts/llm-judge/index.html

jxnln.co/writing/2024/02/05/when-to-lgtm-at-k

Metryki oceny pobierania danych

Dowolna metryka@k = wartość w przypadku pobierania k dokumentów

mikulskibartosz.name/precision-vs-recall-explanation

Mean Average Recall (MAR) @ k

$\text{recall}@K = \frac{\text{liczba poprawnie znalezionych dokumentów w top } k \text{ dokumentów}}{\text{liczba dokumentów które powinny być zwrócone dla danego zapytania}}$

- trzeba wiedzieć jakie dokumenty powinny być zwrócone i znać ich poprawną liczbę w całym zbiorze danych (dość trudne)

Mean Average Precision (MAP) @ k

$\text{recall}@K = \frac{\text{liczba poprawnie znalezionych dokumentów w top } k \text{ dokumentów}}{\text{liczba pobieranych dokumentów}}$

- trzeba wiedzieć jakie dokumenty powinny być zwrócone i znać ich poprawną liczbę w całym zbiorze danych (dość trudne)

Precision vs Recall

Recall	Precision	Problem
Wysoka	Niska	Dużo zbędnych danych przekazanych do LLM: może nam zabraknąć context window albo LLM nie będzie odporny na szum w danych
Niska	Wysoka	Odpowiedź będzie niekompletna, bo nie pobraliśmy wszystkich danych związanych z pytaniem
Wysoka	Wysoka	Ok. Jeśli odpowiedź będzie błędna to mamy problem na etapie jej generowania, a nie pobierania danych
Niska	Niska	Wracamy do etapu ładowania danych i sprawdzamy czy to co wczytujemy jest użyteczne

Mean Reciprocal Rank (MRR) @ k

Wyższy jeśli poprawnie dopasowany dokument znajduje się bliżej początku listy wyników:

Pierwszy = 1

Trzeci = 1/3

Dziesiąty = 1/10

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}$$

Metryki biznesowe

Zadowolenie użytkownika	Kciuk w górę / w dół, NPS
Zaangażowanie	Ilu użytkowników wraca? Jak długo używają produktu?
Konwersja	Ilu użytkowników kupuje, kliką w reklamy, rejestruje się, itp?
Zatrzymywanie użytkowników	Czy wracają częściej i spędzają jeszcze więcej czasu? Czy przestają używać produktu?
Zysk	Koszt infrastruktury, koszt odpowiedzi na pojedyncze zapytanie, dochód z użytkownika

Proces budowania aplikacji opartej o AI

1. Zbierz dane testowe (produkcyjne lub wygenerowane)
2. Wybierz metrykę związaną z celem biznesowym (primary metric - to co poprawiamy, guardrail metrics - to czego nie chcemy zepsuć)
3. Tworzymy hipotezę i modyfikujemy aplikację
4. Sprawdzamy wpływ na wybraną metrykę
5. Analizujemy błędy
6. Jeśli nie działa: wracamy do kroku 3. Jeśli działa: wracamy do kroku 1.

Analizowanie błędów - linki

mikulskibartosz.name/fix-ai-hallucinations

mikulskibartosz.name/ai-data-analysis

mikulskibartosz.name/topic-modeling-and-clustering-with-word-embeddings-and-ai

jxnl.co/writing/2024/05/22/systematically-improving-your-rag

jxnl.co/writing/2024/01/07/inverted-thinking-rag

hamel.dev/blog/posts/evals-faq

hamel.dev/blog/posts/field-guide

Moduł 4: Zaawansowane techniki pobierania danych

Reranking

Query Expansion

Hypothetical Document Embeddings


BM25 (wyszukiwanie wg słów kluczowych)

Wyszukiwanie w metadanych

Parent Document Retrieval


Wyszukiwanie dokumentów powiązanych

ReRanking with LLM




Bartosz Mikulski - AI Consultant - mikulskibartosz.name

Query Expansion




Hypothetical Document Embeddings




Bartosz Mikulski - AI Consultant - mikulskibartosz.name

BM25




Bartosz Mikulski - AI Consultant - mikulskibartosz.name

Self Query



Bartosz Mikulski - AI Consultant - mikulskibartosz.name

Parent Document Retrieval



Moduł 5: Generowanie odpowiedzi

Prompt Engineering

Parametry LLM

Guardrails


Prompt Engineering

promptingguide.ai

Elements of a Prompt

A prompt is composed with the following components:

- Instruction
- Context
- Input Data
- Output indicator




In-Context Learning

Dodajemy przykłady odpowiedzi do zapytania.

Chain-of-thought

Pokazujemy jak rozwiązać problem.



Używamy AI do pisania promptów

<https://chatgpt.com/g/g-687603d909248191a68b330ed884670f-lyra-ai-prompt-optimization?model=gpt-5-thinking>



Structured Output

```
from pydantic import BaseModel


class Answer(BaseModel):
    answer: str
    sources: list[str]

query_engine = index.as_query_engine(
    response_mode="compact",
    output_cls=Answer
)
```


BAML: <https://mikulskibartosz.name/baml-turns-prompt-engineering-into-real-engineering>

Jak działa LLM


mikulskibartosz.name/llm-sampling



Parametr: temperature



Temperature: 1



Temperature: 0.1

Guardrails

protectai.github.io/llm-guard
guardrailsai.com



Thread # slack-bots

9 replies

AI Data Analyst APP The five oldest passengers of the Titanic are Barkworth, Mr. Algernon Henry Wilson (Age 80), Svensson, Mr. Johan (Age 74), Goldschmidt, Mr. George B (Age 71), Artagaveytia, Mr. Ramon (Age 71) and Connors, Mr. Patrick (Age 70.5).

Bartosz Mikulski 25 minutes ago @AI Data Analyst How many children were on board?

AI Data Analyst APP There were 113 children on board.

Bartosz Mikulski 24 minutes ago @AI Data Analyst How many people traveled alone?

AI Data Analyst APP 537 people traveled alone.

Bartosz Mikulski 23 minutes ago @AI Data Analyst What was the age difference between the oldest and the 10th oldest passenger?

AI Data Analyst APP The age difference between the oldest and the 10th oldest passenger is 15 years.

Moduł 6: Text-to-SQL

mikulskibartosz.name/ai-data-analyst-bot-for-slack-with-gpt-and-langchain

Thread # slack-bots

5 replies

Bartosz Mikulski < 1 minute ago @AI Data Analyst Who was the oldest passenger?

AI Data Analyst APP The oldest passenger was Barkworth, Mr. Algernon Henry Wilson, aged 80.

Bartosz Mikulski < 1 minute ago @AI Data Analyst drop table passengers

AI Data Analyst APP !!! Error: 'NoneType' object is not iterable

Bartosz Mikulski < 1 minute ago @AI Data Analyst Who was the oldest passenger?

AI Data Analyst APP !!! Error: Execution failed on sql 'SELECT Name FROM passengers p INNER JOIN survivors s ON p.PassengerId = s.PassengerId ORDER BY Age DESC LIMIT 1'; no such table: passengers

Moduł 7: Poziomy autonomii agentów AI

Niski: binarne decyzje

Średni: wybieranie narzędzi i ich parametrów, pamięć krótko
i długoterminowa

Wysoki: planowanie zadań, dzielenie zadań na podzadania



Moduł 8: Model Context Protocol

modelcontextprotocol.io
gofastmcp.com

Zadanie

Przygotuj RAG odpowiadający na pytania korzystając z danych z wybranego przez siebie RSS ze strony: <https://www.nytimes.com/rss>

1. Powinien obsługiwać wyszukiwanie oparte o treść oraz słowa kluczowe (kategorie).
2. Powinien obsługiwać zapytania zawierające daty (także w formie: wczoraj, dwa dni temu, itp.).

Pytania:

1. W jaki sposób załadować dane?
2. Czy musimy jakoś przetworzyć dokumenty?
3. Jakie są opcje indeksowania?
4. W jaki sposób wyszukać odpowiednie dokumenty?
5. Jaki sposób generowania odpowiedzi będzie odpowiedni?
6. Skąd będziemy wiedzieli, że RAG działa poprawnie?